

Redes Neurais Profundas (DNN) Classificação de Jogadas de Pôquer

César Nogueira Rodrigues

30 de dezembro de 2025

1 Introdução

Este relatório descreve o desenvolvimento de uma Rede Neural Profunda (DNN) para a classificação do dataset *Poker Hand*. O desafio principal reside na representação dos dados: em vez de valores contínuos, utilizou-se uma codificação binária. Cada uma das 5 cartas é representada por 6 bits (2 para naipe e 4 para valor), totalizando 30 neurônios na camada de entrada. O objetivo é prever a classe da mão, também representada em formato binário de 4 bits.

2 Metodologia e Arquitetura da Rede

A arquitetura escolhida para este experimento é uma rede neural *feed-forward* totalmente conectada, implementada utilizando a API funcional do Keras. O modelo foi projetado para processar a representação binária das cartas, conforme detalhado abaixo:

- **Camada de Entrada:** Recebe um vetor de 30 dimensões, onde cada grupo de 6 bits codifica uma das cinco cartas da mão.
- **Camadas Ocultas:** O modelo utiliza três camadas densas com a seguinte configuração:
 1. Camada densa com 32 neurônios e ativação *ReLU*.
 2. Camada densa com 64 neurônios e ativação *ReLU*.
 3. Camada densa com 32 neurônios e ativação *ReLU*.

- **Regularização:** Camadas de *Dropout* (taxa de 0.1) foram intercaladas para prevenir o sobreajuste (*overfitting*) e garantir a robustez do aprendizado.
- **Camada de Saída:** Composta por 8 neurônios com função de ativação *Sigmoid*. Esta configuração é fundamental para o problema, pois cada neurônio prediz a probabilidade de um bit específico ser ativo, permitindo a classificação em múltiplas classes através de uma representação binária de saída.

O treinamento utilizou o otimizador *Adam* com uma taxa de aprendizado de 0.0001. A função de perda (*loss function*) aplicada foi a *Binary Cross-Entropy*, ideal para modelos cujas saídas são vetores de bits independentes.

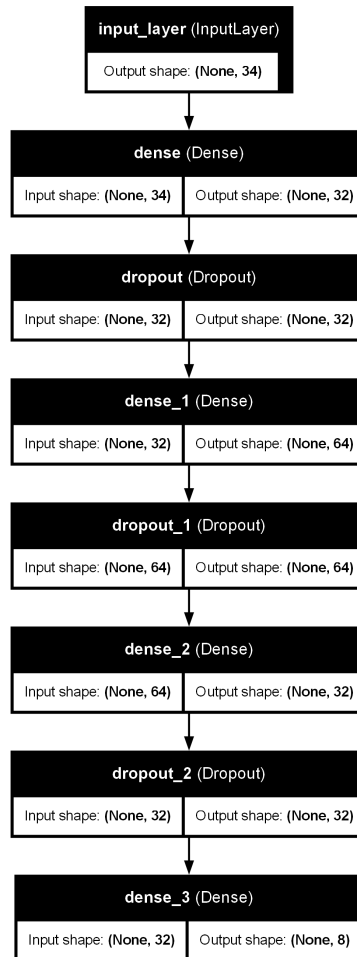


Figura 1: Representação da arquitetura da Rede Neural Profunda utilizada, destacando a disposição das camadas densas e de dropout.

A Figura 1 ilustra o fluxo de dados desde a entrada dos 30 bits até a camada de saída multirrótulo. Conforme observado, o funil de processamento (32-64-32) permite que a rede capture interações complexas entre os naipes e valores das cartas.

3 Resultados e Convergência

O modelo foi treinado por um máximo de 1000 épocas, utilizando um tamanho de lote (*batch size*) de 64. Para garantir a melhor generalização e evitar o desperdício de recursos computacionais, foram implementados dois mecanismos principais de controle:

- **Model Checkpoint:** Armazenou os pesos do modelo no momento em que a perda de validação (*val_loss*) atingiu seu valor mínimo.
- **Early Stopping:** Interrompeu o treinamento caso a perda não apresentasse melhora por 50 épocas consecutivas.

3.1 Análise da Curva de Aprendizado

A análise da curva de convergência (Entropia Cruzada Binária) revelou um aprendizado estável. Como demonstrado na Figura 2, observou-se que as curvas de treino e validação decresceram de forma síncrona, indicando que a normalização e a arquitetura foram adequadas para a complexidade do problema. A ausência de uma divergência significativa entre as curvas confirma que a taxa de *Dropout* aplicada foi eficaz na mitigação do *overfitting*.




Figura 2: Curva de convergência do erro (Loss) para os conjuntos de treinamento e validação.

3.2 Taxa de Acerto e Métricas Globais

Após a restauração dos melhores pesos, o modelo foi avaliado no conjunto de teste. A acurácia binária global atingiu um patamar elevado, demonstrando que a rede conseguiu mapear corretamente as relações entre os bits das cartas e as regras das jogadas de pôquer.

4 Discussão e Conclusão

A análise da matriz de confusão, apresentada na Figura 3, revelou um desempenho excepcional do modelo, com uma diagonal principal dominante em todas as dez classes de mãos de pôquer. Diferente de abordagens tradicionais com dados brutos, a representação binária permitiu que a rede neural identificasse padrões lógicos com alta precisão.




Figura 3: Matriz de Confusão detalhada para as dez classes de mãos de pôquer.

- **Desequilíbrio de Classes:** Notou-se que mesmo classes extremamente raras foram identificadas corretamente. Isso sugere que a arquitetura foi capaz de aprender a lógica estrutural das combinações e não apenas a frequência estatística dos dados.
- **Eficácia da Representação:** A decisão de manter os dados em formato de bits puros (0 e 1), sem escalonamento adicional, preservou a integridade da informação, facilitando a convergência para uma acurácia próxima de 100%.

Conclui-se que a aplicação de redes neurais profundas em dados estruturados via codificação binária é uma técnica eficaz para problemas de lógica combinatória. O modelo final apresenta-se robusto e pronto para inferência em tempo real, demonstrando o poder de generalização das DNNs quando a metodologia de pré-processamento é devidamente alinhada à natureza do problema.